2021 级

《大数据存储与管理》课程

实 验 报 告

姓　名 黄宇

学　号 U202115436

班　号 CS2104 班

日　期 2024.04.20

一、选题

选题 1： 基于 Bloom Filter 的设计

基于 Bloom Filter 的多维数据属性表示和索引

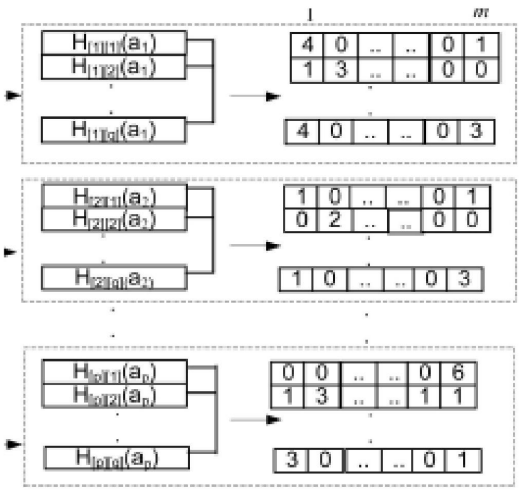

二、实验结构

2.1 数据结构的设计

在处理多维数据时，若采用基于 Bloom Filter 的数据结构，则会用到 MDBF，也即多维布隆过滤器。在 MDBF 中采用多个标准的 Bloom Filter 组成，其个数等同于所需存储数据的维数。在元素查询过程中，通过多维元素各个属性值是否都存在相应过滤器中。其大体结构如下图所示。

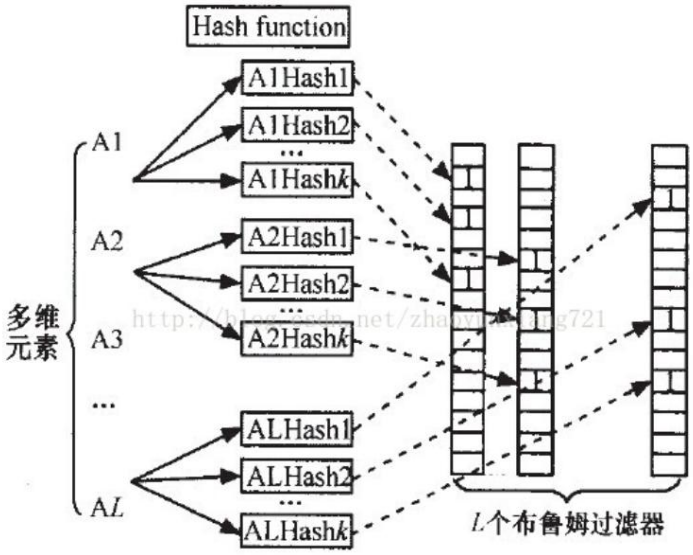

由于多维数据的整体性，通过上述 MDBF 得到的信息会由于单维属性的误判从而导致元素的整体误判，因此我们需要在上述 MDBF 的前提下，再使用一个 Bloom Filter 来存储所有属性联合哈希值。这样是我们能够更精确地判断多维数据地存在性。

举一例说明，但我们存在三维元素{1，2，3}，{4，5，6}时，若不使用额外 Bloom Filter，则当我们检测{1，5，3}时会出现 false positive，而改善后则不会出现该问题。

2.2 操作流程分析

在具体的代码设计中，我采用的是 C++语言。

首先需要定义 Bloom Filter 的类。可以使用 C++标准库中的 bitset 存储位数组，而哈希函数可以使用 C++标准库中提供的 std::hash 计算哈希值（当然也可以使用其它哈希函数，本实验中采用库中函数）。得到如下代码：

```
class BloomFilter {
private:
    std::bitset<1024> bits; // 选择适当大小的 bitset
    std::hash<std::string> hash_fn1;
    std::hash<std::string> hash_fn2;

public:
    void add(const std::string& item) {
        auto hash1 = hash_fn1(item) % bits.size();
        auto hash2 = hash_fn2(item) % bits.size();
        bits.set(hash1);
        bits.set(hash2);
    }

    bool possiblyContains(const std::string& item) const {
        auto hash1 = hash_fn1(item) % bits.size();
        auto hash2 = hash_fn2(item) % bits.size();
        return bits.test(hash1) && bits.test(hash2);
    }
};
```

之后为了处理多维数据，我们需要创建一个包含多个 Bloom Filter 的结构，其中每个维度都有一个对应的 Bloom Filter。最后再额外使用一个 Bloom Filter 用于存储属性的联合值。其代码如下所示：

```cpp
class UnionMultiDimensionalBloomFilter {
private:
    std::array<BloomFilter, 3> filters; // 假设有3个维度
    BloomFilter unionFilter; // 用于联合属性

public:
    void add(const std::array<std::string, 3>& items) {
        std::string combined;
        for (size_t i = 0; i < items.size(); ++i) {
            filters[i].add(items[i]);
            combined += items[i]; // 创建联合字符串
        }
        unionFilter.add(combined); // 添加联合字符串到联合 Bloom Filter
    }

    bool possiblyContains(const std::array<std::string, 3>& items) {
        std::string combined;
        for (size_t i = 0; i < items.size(); ++i) {
            if (!filters[i].possiblyContains(items[i])) {
                return false;
            }
            combined += items[i];
        }
        return unionFilter.possiblyContains(combined); // 检查联合 Bloom Filter
    }
};
```

最后定义一个主函数来测试 UMDBF 以验证其功能，其代码如下图所示：

```cpp
int main() {
    UnionMultiDimensionalBloomFilter umdbf;

    // 添加一些数据
    umdbf.add({ "apple", "banana", "cherry" });
    umdbf.add({ "dog", "elephant", "frog" });

    // 测试查询
    std::cout << "Testing 'apple', 'banana', 'cherry': "
        << (umdbf.possiblyContains({ "apple", "banana", "cherry" }) ? "Found" : "Not Found") << std::endl;
    std::cout << "Testing 'apple', 'banana', 'grape': "
        << (umdbf.possiblyContains({ "apple", "banana", "grape" }) ? "Found" : "Not Found") << std::endl;
    std::cout << "Testing 'apple', 'elephant', 'cherry': "
        << (umdbf.possiblyContains({ "apple", "elephant", "cherry" }) ? "Found" : "Not Found") << std::endl;
    return 0;
}
```

2.3 理论分析

由于该实验中采用的是标准 Bloom Filter 实现，因此不会发生 False Negative。因为在 Bloom Filter 中一旦位置为 1，就不会再进行更改，因此总能返回正确值。

对于 False Positive，在我们的联合 Bloom Filter 中增加了额外的检查层次，理论上可以减少因低维错误肯定而认为元素存在的情况。但由于这个额外检查层自身也有可能出现错误肯定，尤其是多个不同属性组合的情况下。

对于其影响因素，大概有以下三点：

哈希函数的选择：选择好的哈希函数可以减少哈希冲突，从而降低错误肯定的概率。

Bloom Filter 的大小：增加 Bloom Filter 的大小可以降低错误肯定的概率，因为它提供了更多的位来存储信息，减少了不同元素哈希值的重叠概率。

哈希函数的数量：使用更多的哈希函数可以更均匀地分布哈希值，但也可能增加设置位的数量，导致更高的错误肯定概率。

2.4 实验测试性能

根据测试集可以得到结果如下图：

```
Testing 'apple', 'banana', 'cherry': Found
Testing 'apple', 'banana', 'grape': Not Found
Testing 'apple', 'elephant', 'cherry': Not Found
```

对于简单测试集，能得到相应结果。由于加入了额外的检查层，空间开销相较于前将会增大。

假设我们的Bloom Filter使用的是长度为m位的位数组。在原始的多维Bloom Filter 中，如果有 d 个维度，每个维度使用一个独立的 Bloom Filter，那么总的位数为 d*m。增加了一个维度后，总的位数变为（d+1）*m。由此可知，当我们的数据位数越长，所需的空间开销则越多。

三、实验总结与心得

本次实验其数据结构主要完成了对多维联合 Bloom Filter 的代码实现，其具体实现原理并不复杂，本实验中所呈现的联合 Bloom Filter 较为简易，总体上能反映出算法的基本思想。