华中科技大学

大数据存储系统与管理课程报告

姓　　名：　　刘少东

学　　院：　　计算机科学与技术学院

专　　业：　　计算机科学与技术

班　　级：　　CS2102

学　　号：　　U202190067

指导教师：　　华宇

分数	
教师签名	

2024 年 4 月 22 日

一、实验背景

多维布鲁姆过滤器（MDBF）是布鲁姆过滤器（Bloom Filter）的扩展，它允许在多个维度上有效地表示和查询数据。布鲁姆过滤器是一种空间效率极高的数据结构，用于测试一个元素是否是一个集合的成员，而 MDBF 则针对具有多个属性的数据项进行了优化。

MDBF 通过为数据集中的每个维度使用独立的布鲁姆过滤器来工作。例如，如果数据集包含颜色、大小和形状三个维度，MDBF 将为每个维度创建一个布鲁姆过滤器。当一个数据项被添加到 MDBF 时，它的每个属性都会被映射到相应维度的布鲁姆过滤器中。

查询时，MDBF 可以同时在多个维度上进行，这通过检查每个相关维度的布鲁姆过滤器来完成。只有当所有相关维度的布鲁姆过滤器都表明属性可能存在时，MDBF 才会报告数据项可能存在。

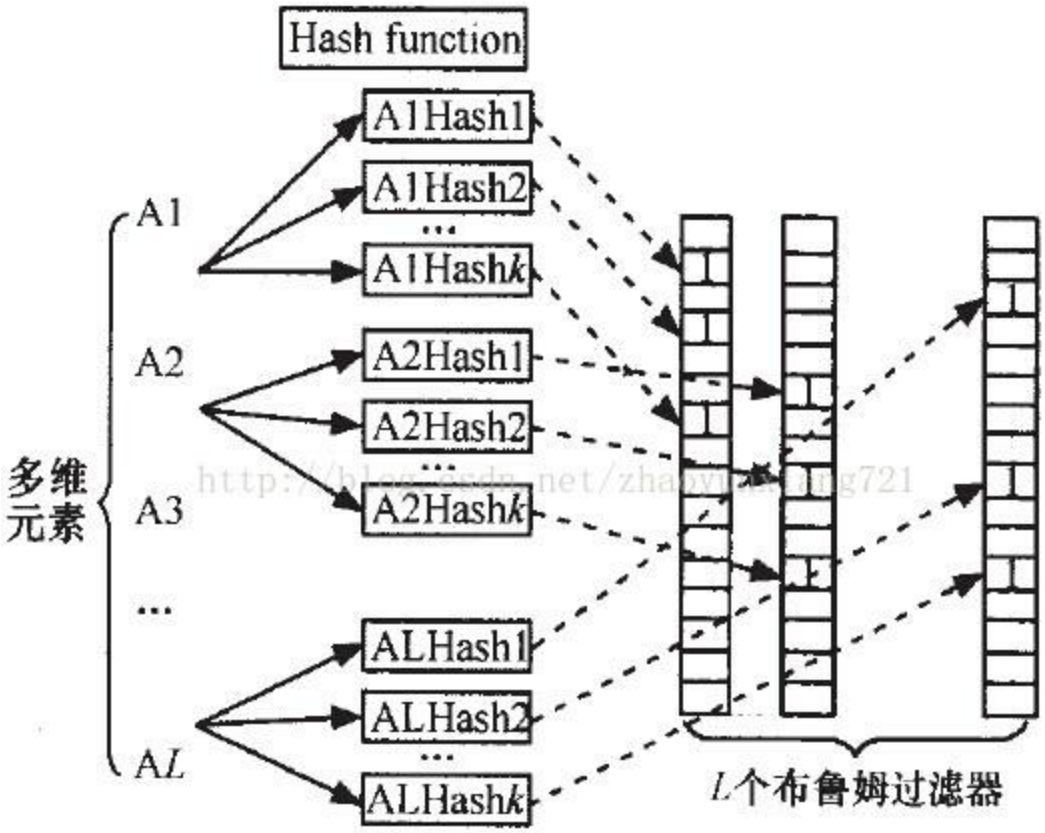

二、布隆过滤器设计

定义一个布隆过滤器

图 1 布隆过滤器数据结构

```python
from pybloom_live import BloomFilter

class MultiDimensionalBloomFilter:
    def __init__(self, capacity, error_rate):
        self.filters = {}
        self.capacity = capacity
        self.error_rate = error_rate

    def add(self, data_point):
        for key, value in data_point.items():
            if key not in self.filters:
                self.filters[key] = BloomFilter(capacity=self.capacity, error_rate=self.error_rate)
            self.filters[key].add(value)

    def query(self, query_dict):
        return all(key in self.filters and value in self.filters[key] for key, value in query_dict.items())
```

增加数据点，测试布隆过滤器

图 2 数据点

```python
# 示例使用
mdbf = MultiDimensionalBloomFilter(capacity=100, error_rate=0.01)

# 添加数据点
mdbf.add({'color': 'red', 'shape': 'circle', 'size': 'small'})
mdbf.add({'color': 'blue', 'shape': 'square', 'size': 'large'})

# 查询数据点
query1 = {'color': 'red', 'shape': 'circle'}
query2 = {'color': 'green', 'shape': 'triangle'}

print("Query1:", mdbf.query(query1))  # 应该返回True，因为这个组合被添加过
print("Query2:", mdbf.query(query2))  # 应该返回False，除非发生误报
```

在这个示例中，我们定义了一个 MultiDimensionalBloomFilter 类，它包含了一个字典 filters，该字典的键是属性名，值是对应属性的 Bloom Filter。add 方法用于向 MDBF 中添加数据点，它会为每个属性创建或更新一个 Bloom Filter。query 方法用于查询一个数据点是否可能存在于 MDBF 中，它会检查查询中的每个属性是否都在对应的 Bloom Filter 中。

由于 Bloom Filter 的特性，如果 query 方法返回 True，这并不保证查询的数据点一定存在于 MDBF 中，只能说它可能存在（可能发生误报）。如果返回 False，

则可以确定查询的数据点一定不存在于 MDBF 中。

三、理论分析

布隆过滤器不存在 false negative 问题

而对于 false positive 问题，根源来自于 hash 冲突，因此可通过增加位数组大小、采用更均匀的 hash 函数、降低存储量等方式缓解。

四、性能分析

Bloom Filter 的空间效率：Bloom Filter 是一种空间效率极高的数据结构，它使用比传统数据结构（如哈希表或二叉树）少得多的空间来表示集合。在 MultiDimensionalBloomFilter 中，对于每个维度都创建了一个独立的 Bloom Filter，这意味着空间开销随着维度的增加而线性增加。如果每个维度的数据点分布较为均匀，那么这种设计可以保持较高的空间效率。

动态创建 Bloom Filter：在 add 方法中，如果遇到一个新的维度（即该维度的 Bloom Filter 尚未创建），则会动态创建一个新的 Bloom Filter。这种动态创建策略意味着空间使用是按需分配的，有助于减少未使用空间的浪费。

添加操作（add 方法）：每个数据点的添加操作涉及到对每个属性的遍历，以及可能的 Bloom Filter 创建和哈希计算。由于 Bloom Filter 的哈希计算通常很快，所以添加操作的时间复杂度主要取决于数据点的属性数量。对于具有固定数量属性的数据点，这个操作的时间复杂度是常数级别的。

查询操作（query 方法）：查询操作的时间效率同样取决于查询字典中的键值对数量。由于 Bloom Filter 的查询操作是非常快速的（通常是常数时间），整个查询操作的时间复杂度也是常数级别的，前提是查询条件的数量固定。

Bloom Filter 的误报率：Bloom Filter 具有一定的误报率（false positive rate），即它可能错误地报告一个不在集合中的元素为存在。

MultiDimensionalBloomFilter 中的每个 Bloom Filter 都有自己的误报率，这个误报率在初始化时通过 error_rate 参数指定。整个 MultiDimensionalBloomFilter 的误报率取决于各个维度 Bloom Filter 误报率的组合。

减少误报率：要减少整个 MultiDimensionalBloomFilter 的误报率，可以通过减少每个维度 Bloom Filter 的误报率来实现，例如通过增加 Bloom Filter 的大小或使用更多的哈希函数。然而，这会以增加空间开销为代价。